
TensorFlow, Keras

Gustavo Gomides


CE229

Sumário

- Introdução
- TensorFlow
- Keras
- Aplicação Prática
- Conclusão

Introdução

Figura 1: TensorFlow, Keras



Fonte: medium.com [1]

Inteligência Artificial

*“O estudo das faculdades mentais pelo uso de modelos computacionais.”
(Charniak e McDermott, 1985) ^[2]*

“A arte de criar máquinas que executam funções que exigem inteligência quando executadas por pessoas.” (Kurzweil, 1990) ^[3]

“Inteligência Computacional é o estudo do projeto de agentes inteligentes.” (Poole et al., 1998) ^[4]

Redes Neurais Artificiais

“As redes neurais artificiais representam uma tecnologia que tem raízes em muitas disciplinas: neurociências, matemática, estatística, física, ciência da computação e engenharia.” [5]

“Uma rede neural pode ser considerada como uma técnica de processamento de dados que mapeia, ou relaciona, algum tipo de fluxo de entrada de informações para um fluxo de saída de dados.” [6]


Processos de Aprendizados

- **Supervisionado:**
 - agente externo indica a resposta desejada para o padrão de entrada
- **Não Supervisionado:**
 - quando não existe um agente externo (auto-organização)
- **Reforço:**
 - quando um crítico externo avalia a saída da rede ^[7]

Neurônio de McCulloch e Pitts


- Primeiro modelo de neurônio artificial desenvolvido - 1943

Figura 2: Neurônio de McCulloch e Pitts



Neurônio não-linear


Figura 3: Modelo não-linear de um neurônio



Fonte: adaptado de Haykin (2001 [8])

Rede Neural

Figura 4: Exemplo de rede neural



Fonte: medium.com [9]

Convolutional Neural Network

CNN

Convolutional Neural Network (CNN)

- Inspirada nos processos biológicos

- Variação de perceptrons multi camada desenvolvidos de modo a demandar o mínimo de pré processamento possível
- Usada principalmente em reconhecimento de imagens e processamento de vídeo^[17]

CNNs possuem geralmente 3 hidden layers

Figura 5: CNN






Figura 5: CNN



- **Convolutional Layers:** aplica operações de convolução nos dados de entrada
- **Pooling Layers:** combina as saídas dos neurônios em uma camada em um único neurônio na próxima camada
- **Fully Connected Layers:** conecta todos os neurônios em uma camada para cada neurônio em outra camada^[17]

TensorFlow

Figura 6: TensorFlow



Fonte: www.tensorflow.org [10]

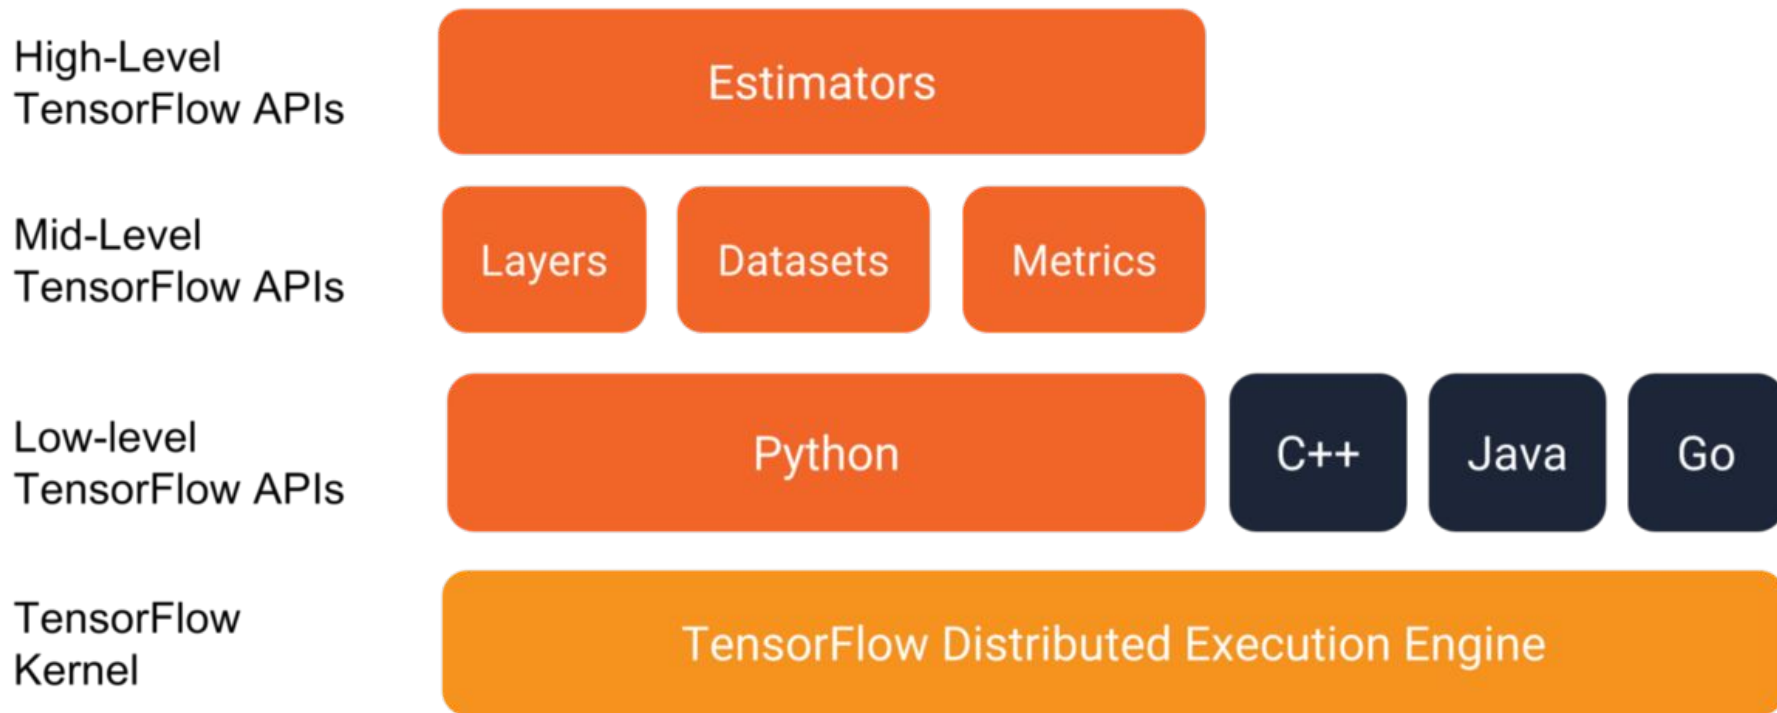
TensorFlow

- Biblioteca open-source para computação numérica usando grafos computacionais.^[11]
- Originalmente desenvolvido pela Google Brain Team na organização de pesquisa Machine Intelligence do Google para Deep Learning.^[11]
- Lançada em 09 de novembro de 2015, sendo a primeira versão estável (1.0.0) em 11 de fevereiro de 2017.^[10]
- Atualmente encontra-se na versão 1.12.2.^[10]

Figura 7: Empresas que utilizam TensorFlow



Figura 8: TensorFlow Stack



Fonte: medium.com [13]

Tensor

- Tensor pode ser visualizado com um array multidimensional de números^[12], sendo que:
 - um escalar é um tensor
 - uma matriz é um tensor
 - um vetor é um tensor

| |
|---|
| 7 |
|---|

Tensor de dimensão [1]

| |
|---|
| 5 |
| 8 |
| 3 |
| 2 |

Tensor de dimensão [5]

| | | | |
|---|---|---|---|
| 4 | 7 | 6 | 2 |
| 5 | 4 | 5 | 6 |
| 2 | 7 | 5 | 1 |
| 9 | 0 | 6 | 6 |

Tensor de dimensão [4, 4]

Data Flow

- Toda a computação é representada em grafos:
 - Nós são as operações
 - Arestas são os tensores
- Consiste em duas fases:
 - construção do grafo
 - execução do grafo

Figura 9: Exemplo de operação TensorFlow

```
import tensorflow as tf  
  
tf.reset_default_graph()
```


```
# y = 2 * A + B
```

construção do grafo

```
with tf.name_scope("y"):  
    dois = tf.constant(2, name="dois")  
    A = tf.constant(3, name="A")  
    B = tf.constant(5, name="B")  
    mul_op = tf.multiply(dois, A, name='mul')  
    soma_op = tf.add(mul_op, B, name='sum')
```

execução


```
with tf.Session() as sess:  
    y = sess.run(soma_op)  
    print("y = {}".format(y))  
    writer = tf.summary.FileWriter('exemplos/ex1', sess.graph)
```



Fonte: próprio autor

Keras

Figura 10: Keras



Fonte: keras.io [14]

Keras

- High-level neural networks API
- Escrito em Python
- Foco principal em propiciar o rápido desenvolvimento das redes neurais

Figura 11: Keras level



Fonte: junyeelee [15]

TensorFlow vs Keras^[16]

| | High-level | Velocidade | Arquitetura | Debugging | Dataset | Popularidade | TOTAL |
|------------|------------|------------|-------------|-----------|---------|--------------|-------|
| TensorFlow | | | | | | | 2 |
| Keras | | | | | | | 4 |

TensorFlow

- Alta performance
- Maiores funcionalidades
- Execução mais rápida em grandes datasets

Keras

- Rápida prototipação
- Suporte a múltiplos back-end
- Código mais fácil

Aplicação Prática

MNIST^[19]

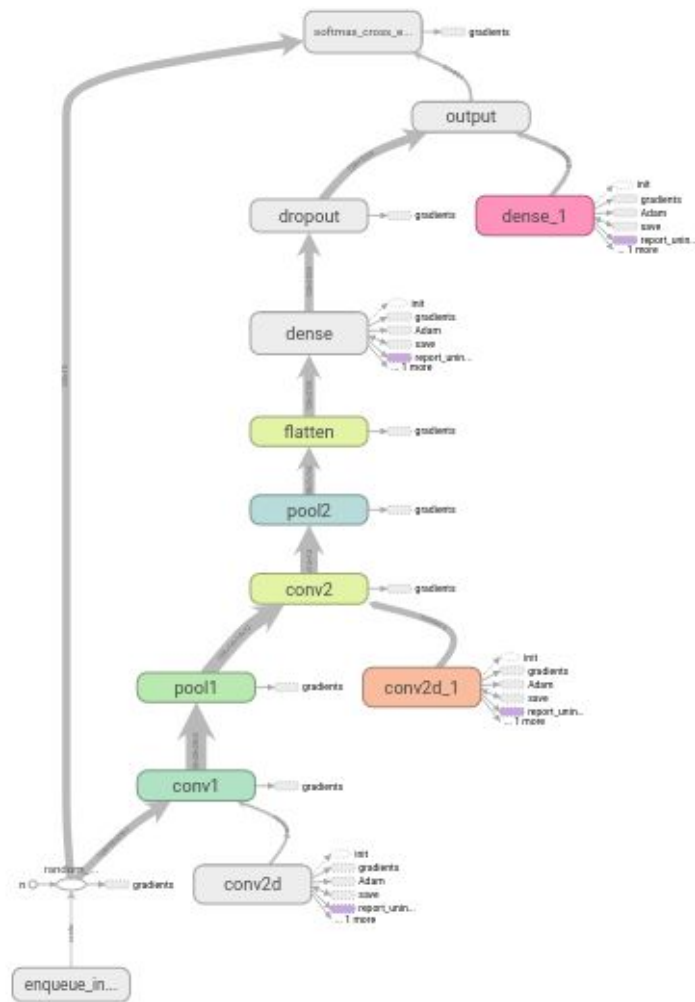
- Dataset com dígitos manuscritos:
 - 60000 dados de treinamento
 - 10000 dados de teste
- Imagens 28 x 28

Figura 11: MNIST



Fonte: [yashk2810.github.io](https://github.com/yashk2810) [20]

CNN



TensorFlow Estimator

mnist_tf_estimator.py

```
def build_cnn(features, labels, mode):
    input_layer = features['X']

    with tf.name_scope("conv1"):
        conv1 = tf.layers.conv2d(inputs = input_layer, filters = 32, kernel_size=[5,5], activation = tf.nn.relu,
                                   padding = 'same')

    with tf.name_scope("pool1"):
        pooling1 = tf.layers.max_pooling2d(inputs = conv1, pool_size = [2,2], strides = 2)

    with tf.name_scope("conv2"):
        conv2 = tf.layers.conv2d(inputs = pooling1, filters = 64, kernel_size = [5,5], activation = tf.nn.relu,
                                   padding = 'same')

    with tf.name_scope("pool2"):
        pooling2 = tf.layers.max_pooling2d(inputs = conv2, pool_size = [2,2], strides = 2)

    with tf.name_scope("flatten"):
        flattening = tf.reshape(pooling2, [-1, 7 * 7 * 64])

    with tf.name_scope("dense"):
        dense = tf.layers.dense(inputs = flattening, units = 1024, activation = tf.nn.relu)

    with tf.name_scope("dropout"):
        dropout = tf.layers.dropout(inputs = dense, rate = 0.2, training=mode == tf.estimator.ModeKeys.TRAIN)

    with tf.name_scope("output"):
        output_layer = tf.layers.dense(inputs = dropout, units = 10)

        predicts = tf.argmax(output_layer, axis = 1)

    if mode == tf.estimator.ModeKeys.PREDICT:
        return tf.estimator.EstimatorSpec(mode = mode, predictions = predicts)

    error = tf.losses.softmax_cross_entropy(onehot_labels=labels, logits=output_layer)

    if mode == tf.estimator.ModeKeys.TRAIN:
        optimizer = tf.train.AdamOptimizer(learning_rate = 0.001)
        train = optimizer.minimize(error, global_step = tf.train.get_global_step())
        return tf.estimator.EstimatorSpec(mode = mode, loss = error, train_op = train)

    if mode == tf.estimator.ModeKeys.EVAL:
        eval_metric_ops = {
            'acc': tf.metrics.accuracy(
                tf.argmax(input=output_layer, axis=1),
                tf.argmax(input=labels, axis=1))
        }

    return tf.estimator.EstimatorSpec(mode=mode, predictions=predicts,
                                       loss=error, eval_metric_ops=eval_metric_ops)
```

Keras

mnist_keras.py

```
def build_cnn():
    model = Sequential()
    model.add(Conv2D(32, kernel_size=(5, 5), activation='relu', input_shape=(28, 28, 1), padding = 'same'))
    model.add(MaxPooling2D(pool_size = [2,2], strides = 2))
    model.add(Conv2D(64, (5, 5), activation='relu', padding = 'same'))
    model.add(MaxPooling2D(pool_size = [2,2], strides = 2))
    model.add(Flatten())
    model.add(Dense(1024, activation='relu'))
    model.add(Dropout(0.2))
    model.add(Dense(10, activation='softmax'))

    model.compile(loss=keras.losses.categorical_crossentropy,
                  optimizer=keras.optimizers.Adam(lr = 0.001),
                  metrics=['accuracy'])

    model.summary()

    return model
```

Comparativo

| | TensorFlow Estimator | Keras |
|------------------------------|----------------------|-------|
| Tempo Desenvolvimento | 3h | 30m |
| Tempo Execução | ~140s | ~366s |
| Linhas Código | 92 | 55 |
| Acurácia | ~97% | ~99% |

Conclusão

Conclusão

- Prototipação e desenvolvimento mais rápido utilizando Keras;
- Alta performance utilizando TensorFlow;
- Não existe biblioteca “bala-prata”.

Referências

- [1] <https://medium.com/tensorflow/training-and-serving-ml-models-with-tf-keras-fd975cc0fa27>
- [2] Charniak, E. and McDermott, D. (1985). Introduction to Artificial Intelligence. Addison-Wesley.
- [3] Kurzweil, R. (1990). The Age of Intelligent Machines. MIT Press.
- [4] Poole, D., Mackworth, A. K., and Goebel, R. (1998). Computational intelligence: A logical approach. Oxford University Press.
- [5] Grupo de Pesquisa em Engenharia de Software. Inteligência Artificial Aprendizagem Supervisionada.
- [6] Azoff E. M. (1994). Neural network time series forecasting of financial markets. Chichester: John Wiley and Sons
- [7] <http://conteudo.icmc.usp.br/pessoas/andre/research/neural/>
- [8] Redes Neurais - 2ed., SIMON S. HAYKIN, 2001
- [9] <https://medium.com/coinmonks/the-artificial-neural-networks-handbook-part-1-f9ceb0e376b4>
- [10] www.tensorflow.org
- [11] <http://datascienceacademy.com.br/blog/o-que-e-o-tensorflow-machine-intelligence-platform/>
- [12] <https://pt.slideshare.net/matthiasfeys/introduction-to-tensorflow-66591270>

- [13] <https://medium.com/@navinkb/beginners-guide-to-tensorflow-by-a-beginner-ebb93e521ece>
- [14] <https://keras.io>
- [15] <http://junyelee.blogspot.com/2018/01/deep-learning-with-python.html>
- [16] <https://www.edureka.co/blog/keras-vs-tensorflow-vs-pytorch/>
- [17] Convolutional neural network. Disponível em: <https://en.wikipedia.org/wiki/Convolutional_neural_network>. Acesso em: 10 nov. 2018.
- [18] <http://www.wildml.com/2015/11/understanding-convolutional-neural-networks-for-nlp/>
- [19] <http://yann.lecun.com/exdb/mnist/>
- [20] <https://yashk2810.github.io/Applying-Convolutional-Neural-Network-on-the-MNIST-dataset/>

Fim!

Gustavo Gomides
`gustavo.gomides7@gmail.com`

`https://github.com/gustavogomides/tensorflow_ce229`